Cinciarelle

Stefano Anzoli Marco Rudelli Marianna Viti

Abstract

In questo studio vengono analizzati i fattori che determinano i colori del piumaggio della specie ornitologica delle Cinciarelle (*Cyanistes caeruleus*), sulla base di un esperimento consistente nella manipolazione della numerosità delle scatole nido installate nella foresta di Wytham Wood (UK). L'obiettivo dell'analisi è valutare l'effetto dell'esperimento e la significatività degli effetti genetici e ambientali nella determinazione della variabile risposta. L'analisi è stata condotta con un approccio multivariato ed i test operati mostrano che, mentre l'effetto genetico appare significativo, l'effetto del trattamento non lo è. Per l'effetto ambientale, i test condotti non sembrano consentire di trarre conclusioni certe.

1. Introduzione

L'esperimento condotto da Simon C. Griffith, dal 2001 al 2006, consiste nella manipolazione delle scatole nido installate nella foresta di Wytham Wood (UK). Entro 14 giorni dalla schiusura delle uova viene modificato il numero di uccelli contenuti nel nido natale: la numerosità può aumentare in seguito all'aggiunta di uccelli provenienti da altri nidi soggetti allo studio, diminuire in seguito allo spostamento degli uccelli in altri nidi, oppure rimanere invariata. Dopo l'esperimento, i pulcini vengono seguiti fino all'età adulta e su di essi vengono effettuate misurazioni relative al colore del piumaggio. Le misurazioni sul colore vengono effettuate anche sui genitori dei pulcini.

L'obiettivo di questo studio è comprendere se l'esperimento ha un effetto sulla colorazione del piumaggio della testa, del petto e delle ali dell'uccello; se fattori ambientali o genetici influenzano il colore e se il fattore genetico è più rilevante di quello ambientale.

Nella Sezione 2 viene descritto il dataset iniziale contenente i dati raccolti; nella Sezione 3 vengono riportate le operazioni di riorganizzazione del dataset e di pulizia dello stesso; nella Sezione 4 si illustrano alcune analisi condotte in fase esplorativa; nella Sezione 5 si definiscono i modelli adattati; nella Sezione 6 si illustrano i test statistici svolti ed i relativi risultati; nella sezione 7 vengono sintetizzate le conclusioni e analizzati i possibili sviluppi futuri dell'analisi.

2. Descrizione del dataset

Il dataset iniziale contiene 11430 unità statistiche, su cui vengono rilevate 162 variabili, di cui qui riportiamo una descrizione non esaustiva. Ogni osservazione rappresenta la rilevazione di una cinciarella, identificata da un codice univoco, della quale sono note, potenzialmente, informazioni relative alla covata, all'allevamento e informazioni riguardanti sia l'ambiente circostante il nido di allevamento sia quello di rilevazione in fase adulta. Queste ultime sono: la densità di cinciarelle nell'area del nido, il numero di coppie di cinciarelle nidificanti entro 50m dal nido, la distanza dal nido di cinciarelle più vicino, il numero di nidi di cinciallegre nel raggio di 50m, il numero di querce entro 50m, la distanza del nido dal bordo del bosco, l'altitudine e livello di calcio nel suolo locale. Inoltre sono noti data e area di nascita, allevamento e rilevazione in età adulta. Sono stati registrati il codice identificativo di entrambi i genitori natali e di entrambi i genitori di allevamento, potenzialmente diversi dai primi. Sono inoltre presenti informazioni relative al trattamento e misurazioni sulla colorazione del piumaggio in età adulta della testa, del petto e delle ali. Per ciascuna delle zone del corpo considerate, sono state rilevate tre diverse misurazioni di colore, trasformate in seguito in tre componenti principali. La variabile di interesse, dunque, consta complessivamente di 9 dimensioni.

3. Pulizia del dataset

3.1. Riorganizzazione delle osservazioni

Il dataset originale contiene, come sopra riportato, una riga per ogni rilevazione di una cinciarella; questa potrebbe essere un uccello oggetto di studio o un genitore. Per raggiungere gli obiettivi dell'analisi, si è quindi preposta una fase di riorganizzazione del dato, finalizzata ad ottenere, per ogni pulcino di cui fossero noti genitori genetici e di allevamento, le informazioni loro riguardanti. Al termine di questa fase, per ogni riga, si hanno le informazioni sulla fase natale, di allevamento e adulta delle cinciarelle monitorate, quelle relative ai genitori genetici e quelle dei genitori di allevamento.

3.2. Gestione dei dati mancanti

Il dataset originale presenta un elevato tasso di valori mancanti. La maggior parte di questi è stata sostituita utilizzando informazioni riguardanti il nido o l'area di riferimento; altri invece sono stati imputati sfruttando il legame tra i pulcini ed i loro genitori. Di seguito riportiamo alcune delle principali operazioni svolte nella gestione dei valori mancanti.

3.2.1. Imputazione della variabile stagione

La variabile relativa alla stagione di misurazione presenta due modalità, w ed s, ad indicare rispettivamente l'inverno e la primavera. I valori mancanti riferiti a tale variabile sono stati

imputati sulla base della variabile riguardante il giorno della misurazione, che assume valori da 1 a 365, a partire dal 1° Gennaio.
Nella fiugra 3.1, viene riportata la distribuzione dei giorni di rilevazione e vengono indicati i range che delimitano le due stagioni sulla base delle osservazioni inizialmente presenti (linee grigie). Considerando i limiti che individuano le quattro stagioni reali (linee rosse), sono stati definiti dei nuovi range (linee verdi) e sulla base dei quali sono stati imputati i valori mancanti della stagione. In definiva, le osservazioni con giorno di misurazione compreso tra 100 e 280 vengono considerate come primaverili e le rimanenti vengono considerate come invernali.

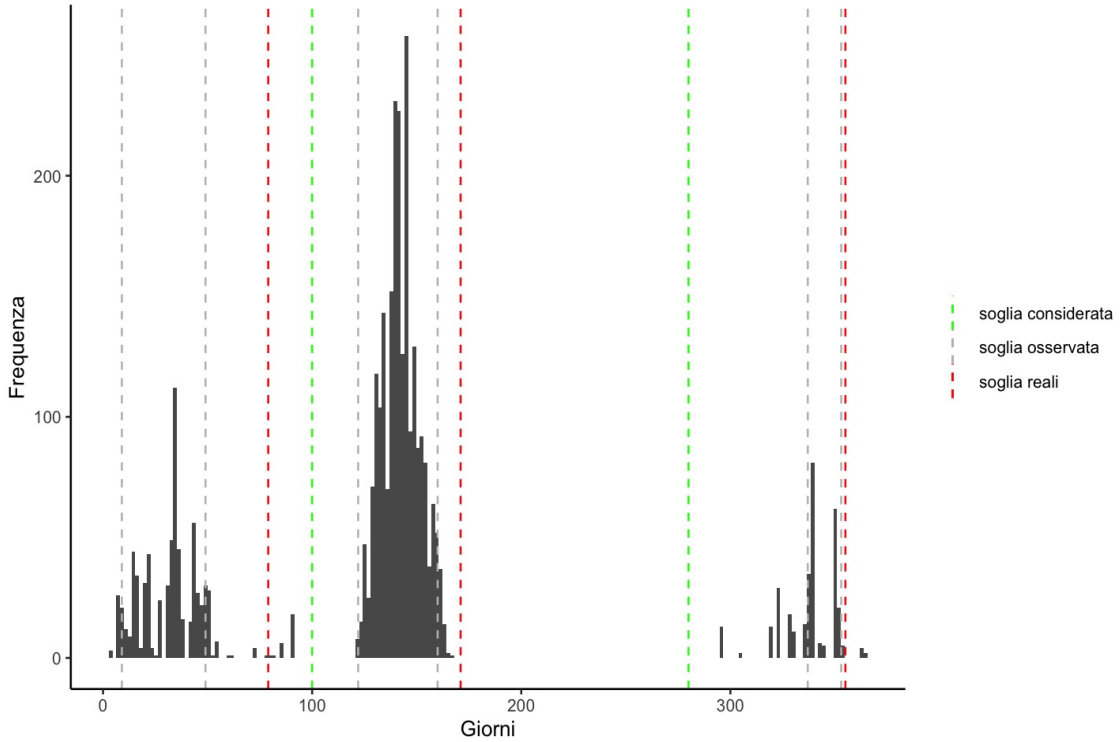

Figure 3.1: Istogramma dei giorni di misurazione con indicazioni sugli estremi delle stagioni

3.2.2. Imputazione delle variabili ambientali

I valori mancanti relativi alle variabili ambientali sono stati imputati utilizzando le medie delle corrispondenti variabili riportate per gli uccelli presenti nelle medesime box nido. Tale scelta appare opportuna alla luce della ridotta variabilità mostrata dalle medie delle variabili ambientali all'interno delle box. Quando tali informazioni non sono risultate reperibili, sono state utilizzate le medie delle variabili ambientali calcolate sulla base delle informazioni registrate per gli uccelli presenti nella medesima area. Valgono considerazioni analoghe circa la variabilità delle rilevazioni per area rispetto a quella globale.

3.2.3. Imputazione delle variabili sulla numerosità degli uccelli nei nidi

Sono state effettuate alcune imputazioni sulle variabili relative alla numerosità degli uccelli nei vari nidi. In particolare, per i valori mancanti relativi al numero di fratelli nel nido di allevamento, è stata calcolata, per ogni nidiata, la media del numero di pulcini presenti (l'operatore di media è stato usato solo per gestire le eventuali incongruenze). Qualora per una data nidiata non fosse presente alcuna informazione riguardo il numero di pulcini, si è proceduto conteggiando il numero di identificativi univoci di individui presenti in quella nidiata. Quest'informazione è stata quindi usata per prevedere il numero di fratelli, attraverso un modello lineare con relazione quadratica; si veda grafico in alto a sinistra della figura 3.2.
Un procedimento analogo è stato eseguito per il numero di fratelli alla schiusura di una data covata a partire dal numero di rilevazioni univoche con il medesimo identificativo di nido natale.
L'imputazione del numero di uova presenti nella covata di cui un adulto è genitore è stata fatta collegando le informazioni dei pulcini appartenenti alla data covata, tramite l'identificativo univoco di questa, e calcolando la media del numero di uova. Si noti come, nella figura 3.2, quando entrambe le informazioni sono presenti, queste corrispondano (quasi) perfettamente.
Una procedura analoga è stata sfruttata per imputare: il numero di pulcini vivi nel nido di un adulto subito dopo la schiusura delle uova sulla base della variabile contenente la stessa informazione relativa ai pulcini; il numero di pulcini presenti nel nido dell'adulto dopo la manipolazione della numerosità del nido a partire dal numero di fratelli nel nido di allevamento del pulcino ed il numero di pulcini allevati fino al quattordicesimo giorno dall'adulto a partire dal numero di fratelli dei pulcini vivi dopo 14 giorni di allevamento.

3.3. Creazione di nuove variabili

Sono state in seguito definite alcune nuove variabili ritenute utili per l'analisi. In particolare, per ogni pulcino di cui si conosce la colorazione del piumaggio da adulto, sono stati calcolati: il tasso pulcini sopravvissuti alla schiusura nel nido natale, il tasso di fratelli sopravvissuti dopo 14 giorni nel nido natale e nel nido di allevamento. Per le nidiate di cui un adulto è genitore, sono stati calcolati: il tasso di pulcini sopravvissuti alla schiusura e dopo 14 giorni dalla schiusura. Sono stati inoltre calcolati due indici per misurare la variazione del numero di pulcini in seguito al trattamento: la differenza ed il log rapporto dei pulcini prima e dopo il trattamento.

3.4. Selezione delle variabili

Nell'ultima fase della pulizia del dataset, sulla base della struttura descritta nella sezione 3.1, è stata operata una selezione preliminare delle variabili. Prima della selezione, per ogni osservazione, si avevano informazioni su:

- cinciarelle in età infantile

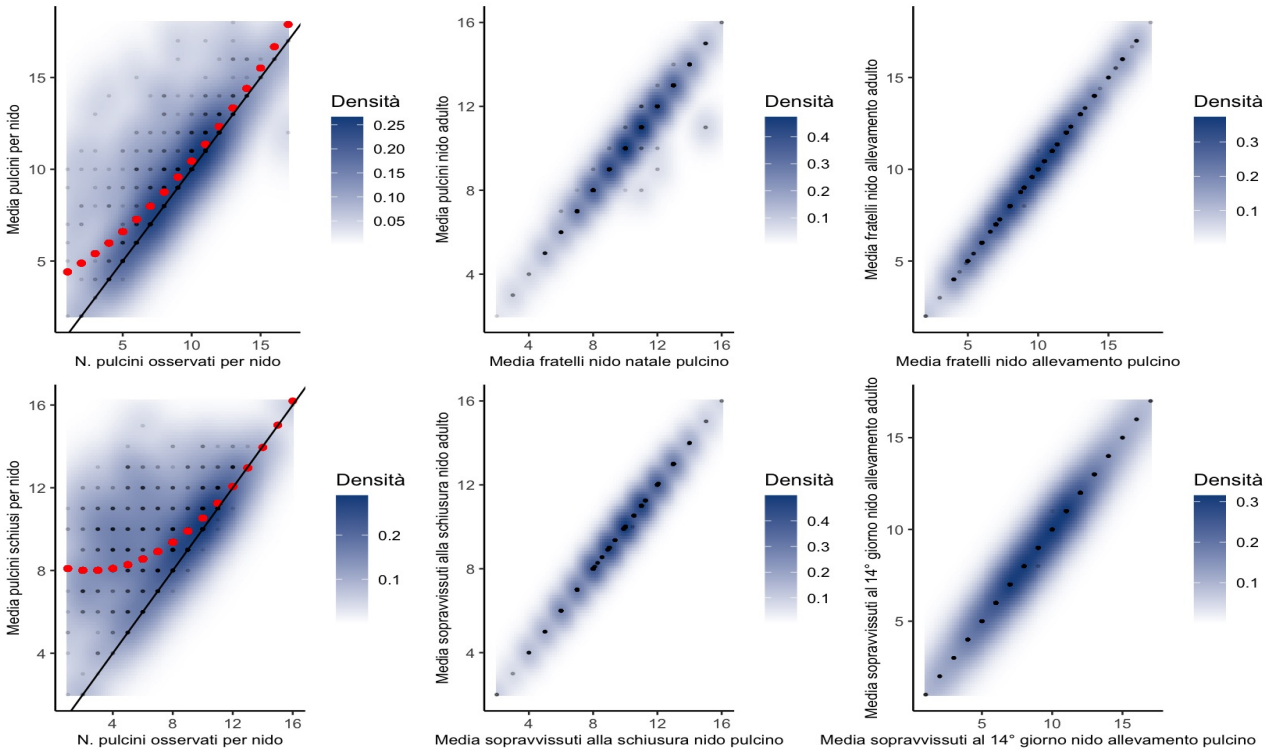

Figure 3.2: Scatter plot della numerosità dei pulcini nei nidi in diversi momenti dell'analisi

  - nidiata di nascita: codici identificativi dell'uccello, della nidiata e dei genitori genetici, area in cui è collocata, dati di sopravvivenza, numerosità
  - nidiata di allevamento: codici identificativi del nidiata e dei genitori di allevamento, area in cui è collocata, dati di sopravvivenza, informazioni ambientali
  - peso e lunghezza del tarsometatarus 14 giorni dopo la schiusura
  - trattamento: se il pulcino è stato allevato dai genitori genetici e come è variata la numerosità del nido di allevamento

- cinciarelle in età adulta
  - nidiata di appartenenza: codice identificativo della nidiata, area in cui è collocata, informazioni ambientali
  - anno e stagione della rilevazione
  - sesso ed età
  - colori del piumaggio e relative componenti principali

- genitori genetici

  - colori del piumaggio e relative componenti principali
  - nidiata di appartenenza: area in cui è collocato, dati di sopravvivenza, informazioni ambientali
  - sesso ed età
  - anno e stagione della rilevazione
- genitori di allevamento
  - nidiata di appartenenza: area in cui è collocato, dati di sopravvivenza, informazioni ambientali
  - sesso ed età
  - anno e stagione della rilevazione

In seguito alla selezione, le variabili conservate per la fase di analisi sono:

- cinciallegre in età infantile
  - nidiata di nascita: dati di sopravvivenza, numerosità
  - nidiata di allevamento: area in cui è collocata, dati di sopravvivenza, numerosità, informazioni ambientali
  - trattamento: se il pulcino è stato trattato e come è variata la numerosità del nido di allevamento
- cinciallegre in età adulta
  - nidiata di appartenenza: informazioni ambientali
  - anno e stagione della rilevazione
  - sesso ed età
  - componenti principali delle variabili sul colore del piumaggio
- genitori genetici
  - nidiata di appartenenza: dati di sopravvivenza, informazioni ambientali
  - anno e stagione della rilevazione
  - sesso ed età
  - componenti principali delle variabili sul colore del piumaggio
- genitori di allevamento
  - età

Riportiamo alcune considerazioni che hanno guidato la selezione delle variabili.
Le variabili relative alle aree in cui sono collocati i nidi sono state escluse assumendo che l'effetto dovuto all'ambiente sia riassunto dalle più dettagliate variabili ambientali presenti nel dataset.
L'informazione relativa alla lunghezza del tarsometatarus, al peso del pulcino dopo 14 giorni dalla schiusura e l'indicatrice della sopravvivenza del pulcino alla prima stagione riproduttiva sono informazioni potenzialmente influenzate da fattori ambientali, da pressioni dovute al trattamento e da fattori genetici. Si assume che le due variabili non influenzino direttamente la risposta, ma siano solamente correlate ad essa a causa dei fattori oggetto di test. In ottica inferenziale, prevedendo una potenziale perdita di potenza dei test di fattori ambientali, legati al trattamento e genetici, si è deciso di eliminare tali variabili.
Volendo testare l'effetto genetico, si è conservato il colore del piumaggio dei genitori delle cinciarelle. Poiché si assume esso sia legato a caratteristiche relative all'uccello durante la rilevazione ed ai fattori ambientali, sono conservati anche anno, sesso, età, stagione, caratteristiche ambientali e stress dovuto ai pulcini presenti nel nido. Per valutare lo stress a cui i pulcini sono stati sottoposti, si è usata come proxy l'informazione riguardante la sopravvivenza all'interno del nido.
Per i genitori di allevamento, sono d'interesse solo le informazioni riguardanti il nido e l'età dei genitori. Poiché le caratteristiche ambientali e di sopravvivenza sono già presenti nelle informazioni del nido di allevamento dei pulcini, si è considerata solo l'età dei genitori.

3.5. Gestione delle misure ripetute

Gli uccelli, sia quelli soggetti all'esperimento, sia i loro genitori, vengono rilevati potenzialmente più volte. Tali misure ripetute sono state gestite tramite un campionamento casuale pensato per ottenere una sola rilevazione per ogni individuo oggetto di studio. Ad esso vengono associate, nuovamente previo campionamento, delle rilevazioni univoche dei genitori genetici. Si noti che, assumendo che l'apporto genetico del colore del genitore non cambi nel tempo, si è associata una misurazione qualsiasi del relativo genitore al figlio e non necessariamente la rilevazione della medesima covata. L'assegnazione delle informazioni dei genitori di allevamento non richiede campionamento, poiché si è constatato che sono disponibili osservazioni univoche per i genitori che allevano una data nidiata.

4. Analisi descrittiva

Si riportano di seguito alcune delle analisi condotte in fase esplorativa. La figura 4.1 mostra gli scatter plot delle prime due componenti principali dei colori per ciascuna delle zone del corpo rilevate, distinguendo le osservazioni in base al sesso della cinciarella adulta. Risulta evidente come la prima componente principale di testa ed ali assuma valori più elevati nelle femmine, mentre per il petto è la seconda componente principale del colore ad essere discriminante tra i sessi. La figura 4.2 mostra la relazione tra le prime componenti principali di genitori e figli, nelle tre parti del corpo e secondo la distinzione per sesso. Nel caso delle

ali, si nota una potenziale relazione positiva tra i colori del figlio e dei genitori, in particolare con la madre (nonostante la possibile presenza di ulteriori confondenti oltre al sesso). Per le altre due zone, specie per il petto, non emerge alcuna relazione marginale evidente.
Dall'analisi esplorativa non emergono relazioni marginali tra le variabili risposta e le variabili riguardanti il trattamento o quelle sull'ambiente.

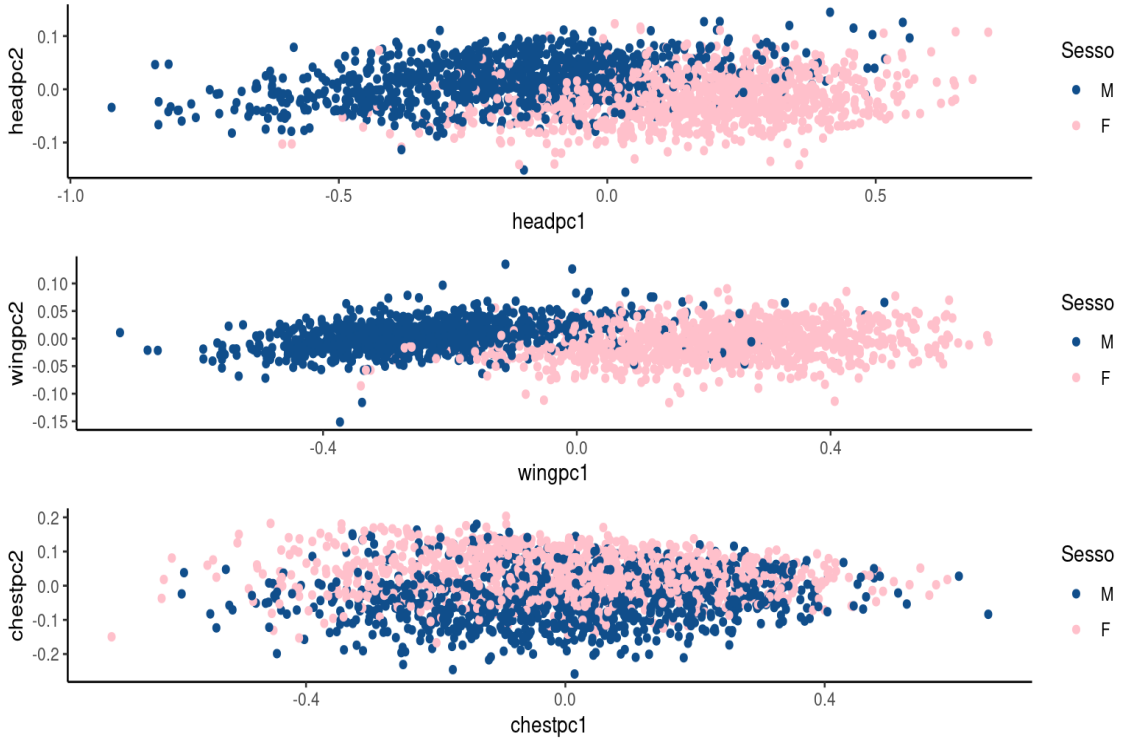

Figure 4.1: Scatter plot delle prime due componenti principali dei colori di testa, ali e collo delle cinciarelle adulte, per sesso

5. Modelli

Nella fase di modellazione dell'analisi, sono stati impiegati dei modelli lineari multivariati, considerando come variabile risposta le nove componenti principali riferite ai colori rilevati sulle cinciarelle adulte. Come anticipato nella Sezione 3.4, è stato considerato come fattore genetico il colore del piumaggio dei genitori. Per ottenere l'informazione genetica si vuole depurare il colore da fattori che possano influenzarne la misurazione, ovvero, informazioni relative all'ambiente circostante il loro nido di riferimento, il sesso, il periodo di rilevazione ed il tasso di sopravvivenza registrato nel loro nido. L'obiettivo è quello di ottenere una misura del colore al netto delle altre covariate disponibili per i genitori genetici. Queste sono dunque state incluse nella stima dei modelli, secondo due modalità:

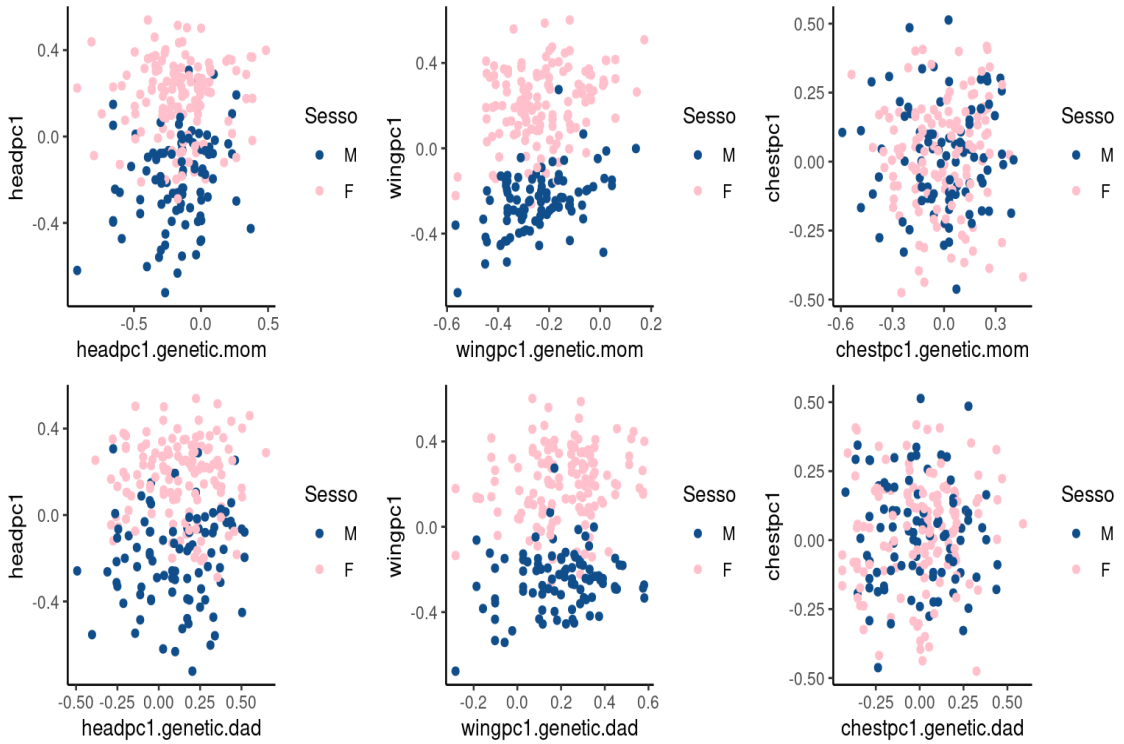

Figure 4.2: Scatter plot della prima componente principale dei colori di testa, ali e collo di figli e genitori, per sesso

- la prima si articola in due fasi: si stima un modello per i colori dei genitori, in funzione delle loro informazioni disponibili; in seguito, si stima un modello per i colori dei figli, avente come esplicative, oltre alle altre informazioni d'interesse, i residui del modello precedente.
- la seconda consiste nella costruzione di un unico modello lineare contenente tutte le informazioni d'interesse relative ai genitori, oltre a quelle relative ai figli.

5.1. Modello lineare in due step

La prima opzione esplorata consiste nella stima di un modello lineare multivariato per le variabili relative ai colori dei genitori, seguita dalla stima di un modello lineare multivariato per i colori dei figli, includendo tra le esplicative i residui del primo modello. I modelli stimati sono dunque i seguenti

$$y_{par_{ij}} = \delta_{0_j} + \delta_{1_j} x_{par.env_i} + \delta_{2_j} x_{par.info_i} + \epsilon_{ij}$$

Dove

- $i = 1, ..., 1397$ e $j = 1, ..., 9$

- $y_{par_{ij}}$: colori dei genitori
- $x_{par.env_i}$: informazioni sull'ambiente circostante il nido in cui avviene la rilevazione
- $x_{par.info_i}$: altre informazioni relative alla cinciarella (momento della rilevazione, sopravvivenza degli uccelli, sesso, età)

$$y_{ckr_{ij}} = \beta_{0_j} + \beta_{1_j} x_{ckr.treat_i} + \beta_{2_j} x_{rear.env_i} + \beta_{3_j} x_{ad.env_i} + \beta_{4_j} x_{ad.info} \\ + \beta_{5_j} x_{res.dad_i} + \beta_{6_j} x_{res.mom_i} + \epsilon_{ij}$$

Dove

- $i = 1, ..., 221$ e $j = 1, ..., 9$
- y_{ckrij}: colori delle cinciarelle monitorate
- $x_{ckr.treat}$: informazioni sul trattamento del nido
- $x_{rear.env}$: informazioni sull'ambiente circostante il nido di allevamento
- $x_{ad.env}$: informazioni sull'ambiente circostante il nido in cui avviene la rilevazione
- $x_{ad.info}$: altre informazioni relative alla cinciarella (momento della rilevazione, sopravvivenza degli uccelli, ecc.)
- $x_{res.dad}$, $x_{res.mom}$: residui del modello stimato per i colori dei genitori

Questo modello ha la caratteristica di non prevedere una relazione diretta tra variabili che condizionano la rilevazione sui genitori e la risposta dei figli. La relazione tra le covariate e il colore dei genitori è inoltre la stessa per padri e madri.

5.2. Modello lineare unico

Nella seconda versione di modello lineare multivariato adattata, si valuta la relazione tra i colori in età adulta delle cinciarelle monitorate e gli aspetti relativi al trattamento, all'ambiente ed alla genetica. Come appena descritto, la colorazione del piumaggio dei genitori genetici è potenzialmente depurata dalla presenza di relative covariate nel modello. Tali covariate entrano anche in relazione tra loro e con le altre covariate del modello, nonché con la risposta.

$$y_{ckr_{ij}} = \beta_{0_j} + \beta_{1_j} x_{ckr.treat_i} + \beta_{2_j} x_{rear.env_i} + \beta_{3_j} x_{ad.env_i} + \beta_{4_j} x_{ad.info} \\ + \beta_{5_j} (x_{dad.col_i} - \alpha_{0_j} - \alpha_{1_j} x_{dad.env_i} - \alpha_{2_j} x_{dad.info_i}) \\ + \beta_{6_j} (x_{mom.col_i} - \gamma_{0_j} - \gamma_{1_j} x_{mom.env_i} - \gamma_{2_j} x_{mom.info_i}) + \epsilon_{ij}$$

Dove

- $i = 1, ..., 221$ e $j = 1, ..., 9$
- $x_{ckr.treat}$: informazioni sul trattamento del nido
- $x_{rear.env}$: informazioni sull'ambiente circostante il nido di allevamento
- $x_{ad.env}$: informazioni sull'ambiente circostante il nido in cui avviene la rilevazione
- $x_{ad.info}$: altre informazioni relative alla cinciarella (momento della rilevazione, sopravvivenza degli uccelli, ecc.)
- $x_{dad.col}$, $x_{mom.col}$: colore del piumaggio di padre e madre
- $x_{dad.env}$, $x_{mam.env}$: informazioni ambientali del nido di appartenenza di padre e madre al momento della rilevazione
- $x_{dad.info}$, $x_{mom.info}$: altre caratteristiche di padre e madre, come anno e stagione di rilevazione

Il modello, così come definito, potrebbe presentare alcune criticità. Diventa possibile una relazione diretta tra le caratteristiche ambientali dei genitori e la variabile risposta, nonché con le altre variabili presenti nel modello. Questo aumenta la complessità del modello (e la sua flessibilità). Viene inoltre incluso un elevato numero di variabili relative alle caratteristiche ambientali, considerando sia quelle dell'uccello rilevato sia quelle dei suoi genitori. Trattandosi di variabili molto correlate tra loro, potrebbe essere opportuno ridurne la dimensionalità tramite un'analisi delle componenti principali, limitando però la capacità interpretativa del modello e la possibilità di isolare completamente gli effetti da testare. Inoltre, la relazione tra le covariate dei genitori ed il loro colore non è più vincolata ad essere la stessa per padri e madri.

6. Test statistici

Dopo aver adattato i modelli, sono stati condotti 3 test rapporto di verosimiglianza per rispondere alle domande di ricerca circa la significatività degli effetti genetici, ambientali e del trattamento. I test sono stati ripetuti al variare di 1000 ricampionamenti come indicato nella Sezione 3.5. La scelta di limitare la procedura di test a sole 3 macro-categorie deriva dalla necessità di mantenere la potenza dei test a fronte della loro molteplicità.
Per entrambe le tipologie di modello, sono state stimate: la versione completa, contenente tutte le informazioni; la versione priva dell'informazione genetica, ottenuta escludendo le variabili riguardanti i genitori genetici (colori e altre potenziali covariate); la versione priva dell'informazione ambientale, ottenuta escludendo tutte le variabili relative all'ambiente; la versione priva delle informazioni relative al trattamento, ottenuta escludendo tutte le informazioni relative all'esperimento ed al nido in cui l'uccello è stato allevato. Le versioni ridotte sono poi state confrontate con la versione completa del modello tramite test rapporto di verosimiglianza.

Si fa notare che, nella soluzione che prevede un unico modello, quando le variabili ambientali sono riassunte tramite componenti principali, non è più possibile isolare completamente l'informazione ambientale riferita ai genitori da quella dei figli. Questo impedisce di rimuovere le variabili ambientali dei genitori nella fase di test dell'effetto genetico.
Riguardo la procedura di test dell'effetto sperimentale, si è scelto di testare le variabili strettamente collegate al trattamento e alle condizioni di allevamento del pulcino, ovvero, la numerosità del nido di allevamento, il logaritmo del rapporto tra la numerosità del nido natale e quello di allevamento, l'età dei genitori di allevamento ed il tasso di sopravvivenza della nidiata. Non sono state rimosse le variabili ambientali della nidiata, in quanto non sono state interpretate come facenti parte dell'effetto sperimentale.

6.1. e-values

Avendo condotto i test su diversi ricampionamenti e volendone ottenere una valutazione riassuntiva, si è deciso di ricorrere allo strumento degli e-values, calcolati a partire dai corrispondenti p-values. Per il calcolo di queste quantità si è fatto ricorso all'utilizzo di un calibratore (V. Vovk, R. Wang (2021)): a partire dal p-value p di ciascun test, è stato ottenuto l'e-value e come

$$e = F(p) = \frac{1 - p + p \ln p}{p(-\ln p)^2}$$

I valori ottenuti sono poi stati sottoposti ad una correzione per test multipli, secondo l'algoritmo 1 descritto in (V. Vovk, R. Wang (2021)). Un vantaggio derivante dall'utilizzo degli e-values rispetto ai p-values è che i primi sono facili da combinare: il merging di tali quantità si ottiene, semplicemente, tramite media aritmetica, anche in caso di dipendenze tra le quantità oggetto di test. Per ciascuno dei tre test condotti è stato dunque calcolato un e-value complessivo mediando i valori ottenuti dai 1000 ricampionamenti. I risultati sono poi stati interpretati secondo la regola empirica descritta in Appendice.

6.2. Risultati

Si illustrano ora i risultati ottenuti dai tre test condotti su 1000 campioni. La figura 6.1 mostra le densità, al variare dei ricampionamenti, dei p-values dei test condotti, calcolati sulla base del modello 5.1, e del modello 5.2 considerando tutte le variabili ambientali nel primo caso e le prime 10 componenti principali delle stesse nell'altro, e del modello 5.2. Le rette indicano la soglia calcolata con la correzione per test multipli di Bonferroni. Emerge che, mentre l'effetto genetico è plausibilmente significativo, l'effetto ambientale e del trattamento sembrano non esserlo.

La figura 6.2 mostra le densità degli e-values calcolati a partire dai p-values corrispondenti e su cui è stata effettuata la correzione per test multipli. Le rette rosse sono poste in corrispondenza del valore che limita superiormente la media della distribuzione di un e-value sotto ipotesi nulla. Le rette colorate indicano la media della distribuzione e quindi il valore dell'e-value complessivo di ogni test. Per l'effetto genetico, tali valori sono 10.3402, 4.6640 e 15.4706 per il modello in due step, il modello unico con PCA e il modello unico

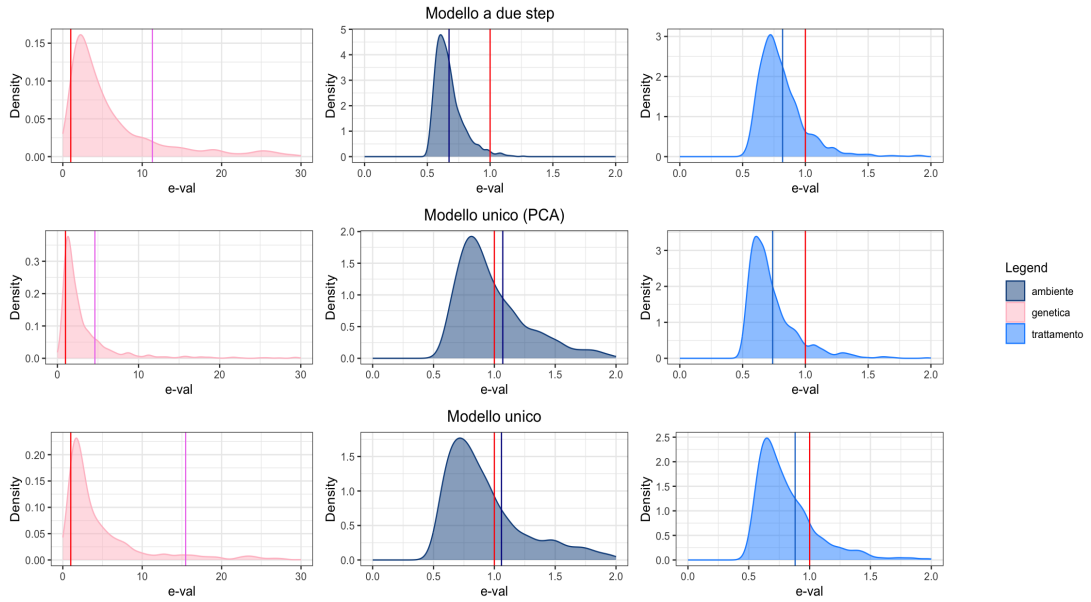

Figure 6.1: p-values dei test condotti

senza PCA, rispettivamente; per l'effetto ambientale si ottengono, nello stesso ordine, i valori 0.8252, 0.7557, 0.9472; per il trattamento si ottengono 0.6742, 1.0883 e 1.1244. Sulla base della regola riportata in Appendice e coerentemente con quanto osservato in precedenza, l'effetto genetico è l'unico ad essere significativo nel modello a due step. Per quanto riguarda il modello unico, si nota una differenza sostanziale nella significatività dell'effetto genetico dovuta alla sintesi tramite PCA delle variabili ambientali. Questo è dovuto all'impossibilità di rimuovere l'informazione ambientale dei genitori dal modello e potrebbe significare che questa ha un effetto predittivo sulla risposta. Per quanto riguarda l'effetto ambientale, si nota un valore medio appena superiore alla soglia, denotandone un comportamento borderline che merita potenzialmente ulteriori indagini. Si noti che, nel modello unico, il test per l'effetto ambientale rimuove anche le variabili ambientali dei genitori. Questo può, da un lato, aumentare la potenza in caso l'effetto delle suddette variabili nei confronti dei colori dei genitori sia presente, dall'altro, inserire bias nella procedura di test qualora fosse presente un effetto diretto (e non strettamente ambientale) tra le variabili ambientali dei genitori e la risposta.

Le figure 6.3, 6.4, 6.5 mostrano i rapporti di R^2 e R^2_{adj} (corretti per il numero di parametri del modello) tra modelli ridotti e del modello completo. Per quanto riguarda il modello a due step (6.3), si nota come i fattori genetici spieghino la maggior proporzione di varianza (circa un decimo), seguiti dai fattori ambientali e, infine, dal trattamento. Correggendo per il numero di coefficienti rimossi, l'andamento generale non cambia, con l'effetto ambientale che si sovrappone per importanza a quello del trattamento. Interpretazioni simili possono essere fatte osservando i grafici relativi al modello unico (6.4, 6.5).

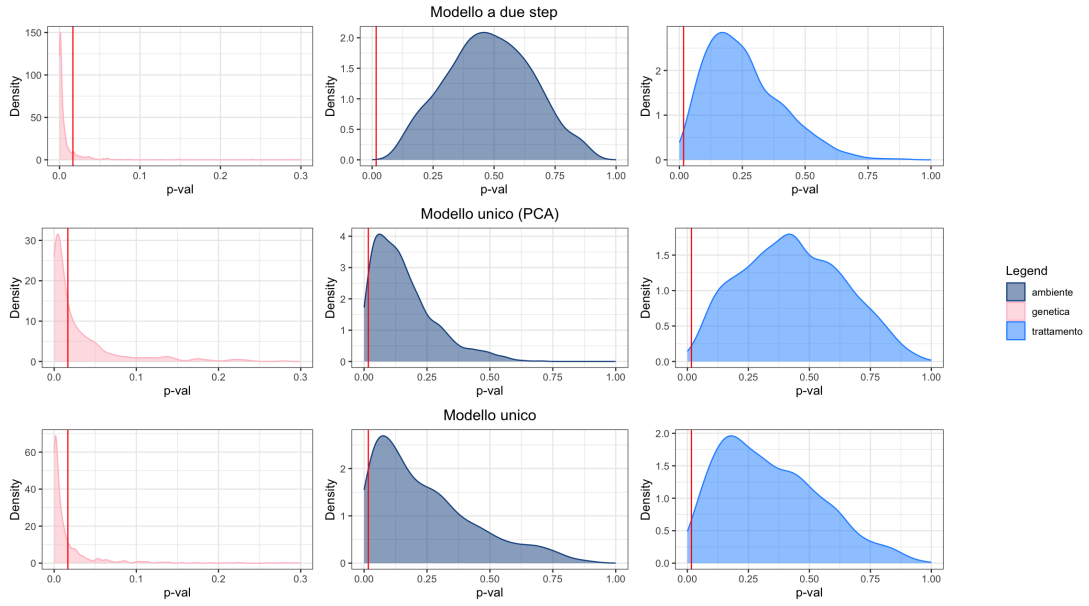

Figure 6.2: p-values dei test condotti

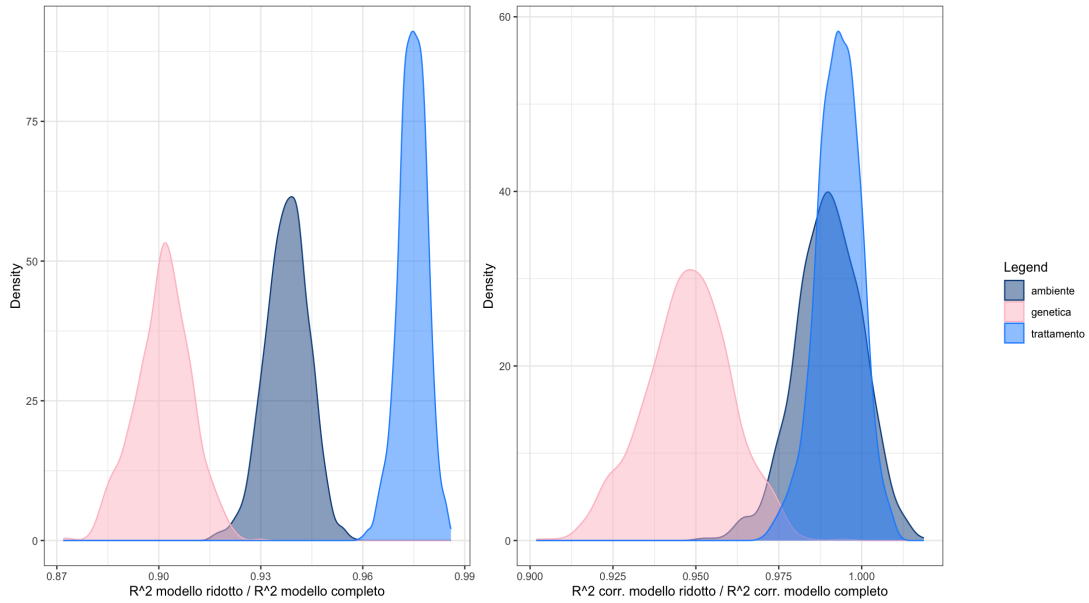

Figure 6.3: Rapporto tra R^2 ed R^2_{adj} tra i modelli ridotti e quello completo tipologia 5.1

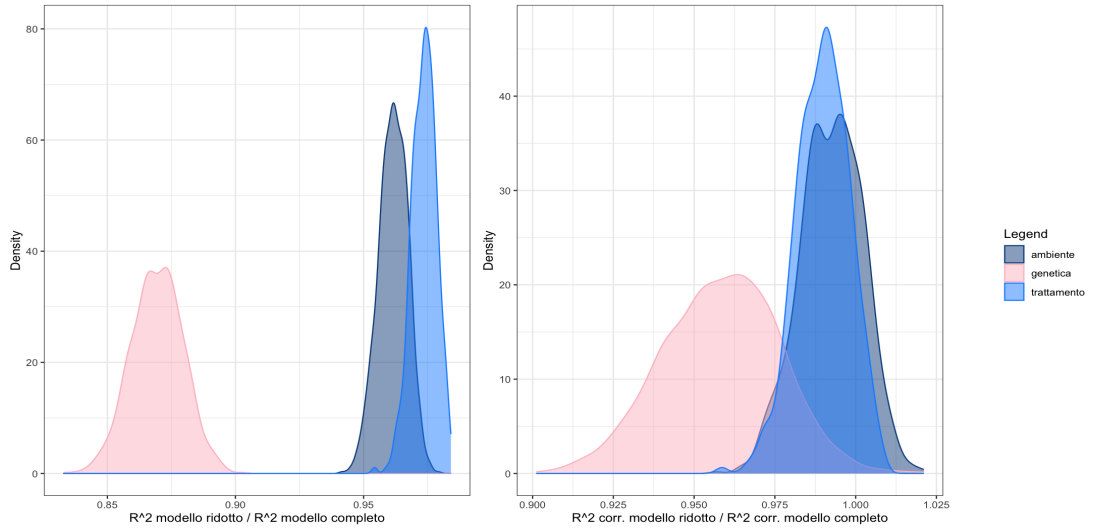

Figure 6.4: Rapporto tra R^2 ed R^2_{adj} tra i modelli ridotti e quello completo tipologia 5.2, con componenti principali ambientali

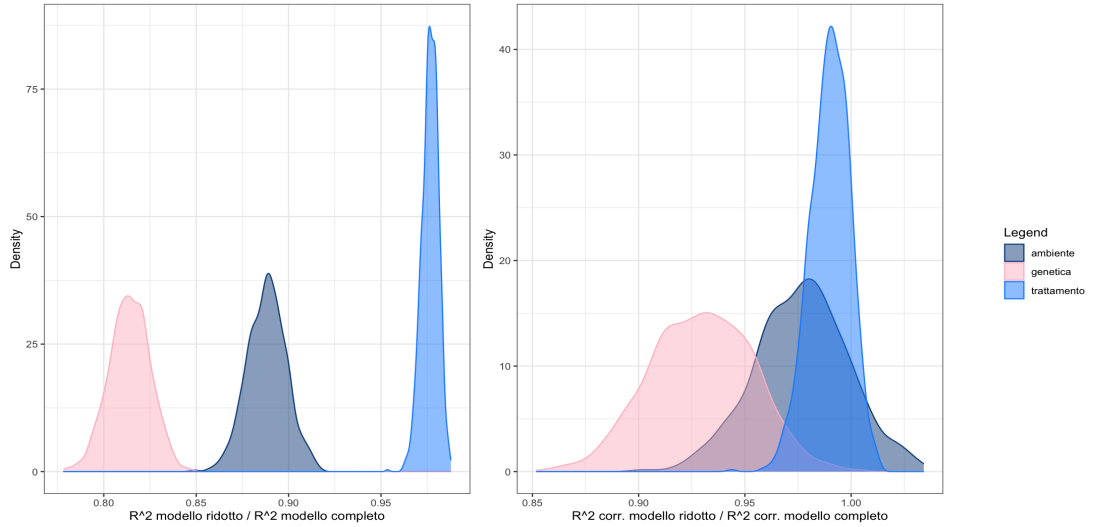

Figure 6.5: Rapporto tra R^2 ed R^2_{adj} tra i modelli ridotti e quello completo tipologia 5.2, senza componenti principali ambientali

7. Conclusioni e sviluppi futuri

Per concludere, dall'analisi condotta una forte evidenza in favore della presenza di effetti di carattere genetico nella determinazione della colorazione del piumaggio delle cinciarelle oggetto di studio. Non sembra essere presente invece un effetto dovuto all'esperimento

svolto. Per quanto riguarda la componente ambientale, i risultati non sembrano sufficientemente significativi per trarre conclusioni certe. Ulteriori valutazioni in questa direzione sono sicuramente necessarie, anche alla luce delle differenze mostrate dai diversi approcci alla modellazione.

Appendice

e-values

Dato lo spazio di probabilità $(\Omega, \mathcal{A}, \mathcal{P})$, una *e-variable* è una variabile causale estesa (può essere ∞) definita come $E : \Omega \to [0, \infty]$ tale che $\mathbf{E}^{\mathcal{P}}[E] \leq 1$. I valori assunti dalle e-variables sono detti *e-values*.
Un *calibratore* è una funzione che consente di trasformare p-values in e-values. Si tratta di una funzione non negativa e decrescente che integra al massimo ad 1 nell'intervallo $[0, 1]$. Data la famiglia di calibratori $f_t(p) = tp^{t-1}$, con $t \in (0, 1)$, la funzione

$$F(p) := \int_0^1 tp^{t-1} dt = \frac{1 - p + p \ln p}{p(-\ln p)^2}$$

produce un e-value prossimo a quello ideale.
In presenza di test multipli, dunque avendo un insieme di ipotesi nulle composite $H_k, k = 1, ..., K$, gli e-values ottenuti per ciascun test, $e_1, ..., e_K$, possono essere aggiustati al fine di ottenere degli e-values corretti, $e_1^*, ..., e_K^*$, tali che $e_k^* \leq e_k \forall k$. La procedura che consente di ottenere gli e_k^* è illustrata nell'algoritmo 1.

Algorithm 1 Adjusting e-values for multiple hypothesis testing

Require: A sequence of e-values $e_1, ..., e_K$
  Find a permutation $\pi : \{1, ..., K\} \to \{1, ..., K\}$ such that $e_{\pi(1)} \leq \cdots \leq e_{\pi(K)}$.
  Set $e_{(k)} := e_{\pi(k)}, k \in \{1, ..., K\}$
  $S_0 := 0$
  for $i = 1, ..., K$ **do**
    $S_i := S_{i-1} + e_{(i)}$
  end for
  for $k = 1, ..., K$ **do**
    $e^*_{\pi(k)} := e_{\pi(k)} \forall k$
    for $i = 1, ..., k - 1$ **do**
      $e := \frac{e_{\pi(k)} + S_i}{i+1}$
      if $e < e^*_{\pi(k)}$ **then**
        $e^*_{\pi(k)} := e$

Per valutare quanto siano significativi i risultati di un test usando gli e-values, è possibile utilizzare una regola empirica secondo cui:

- se l'e-value e è minore di 1, l'ipotesi nulla è supportata
- se $e \in (1, \sqrt{10}) \approx (1, 3.16)$, l'evidenza contro l'ipotesi nulla non vale più che una menzione
- se $e \in (\sqrt{10}, 10) \approx (3.16, 10)$, l'evidenza contro l'ipotesi nulla è sostanziale
- se $e \in (10, 10^{3/2}) \approx (10, 31.6)$, l'evidenza contro l'ipotesi nulla è forte
- se $e \in (10^{3/2}, 100) \approx (31.6, 100)$, l'evidenza contro l'ipotesi nulla è molto forte
- se $e > 100$, l'evidenza contro l'ipotesi nulla è decisiva.

Per ulteriori approfondimenti, si rimanda a (V. Vovk, R. Wang, (2021)).

Bibliografia

Vladimir Vovk. Ruodu Wang. (2021) E-values: Calibration, combination and applications. Ann. Statist. 49 (3) 1736 - 1754

Griffith, S. C. (2000). A trade–off between reproduction and a condition–dependent sexually selected ornament in the house sparrow Passer domesticus. Proceedings of the Royal Society of London. Series B: Biological Sciences, 267(1448), 1115-1119.